

# Projet 2 DAAR 2025

02.11.2025

—

MARSSO Denn 28608482 - MOUGAMADOUBOUGARY Mohamed 28604611  
M2 STL

## LIEN POUR LA DASHBOARD :

<https://my-elasticsearch-deployment-436a04.kb.europe-west9.gcp.elastic-cloud.com/app/r/s/j6kyG>

### I. Elastic API requests

01-02

```
GET ny_restaurants/_search
{
  "size": 0,
  "aggs": {
    "unique_neighborhoods": {
      "cardinality": {
        "field": "NTA"
      }
    },
    "neighborhoods": {
      "terms": {
        "field": "NTA",
        "size": 1000,
        "order": { "_count": "desc" }
      },
      "aggs": {
        "boro": {
          "terms": { "field": "BORO", "size": 1 }
        }
      }
    }
  }
}
```

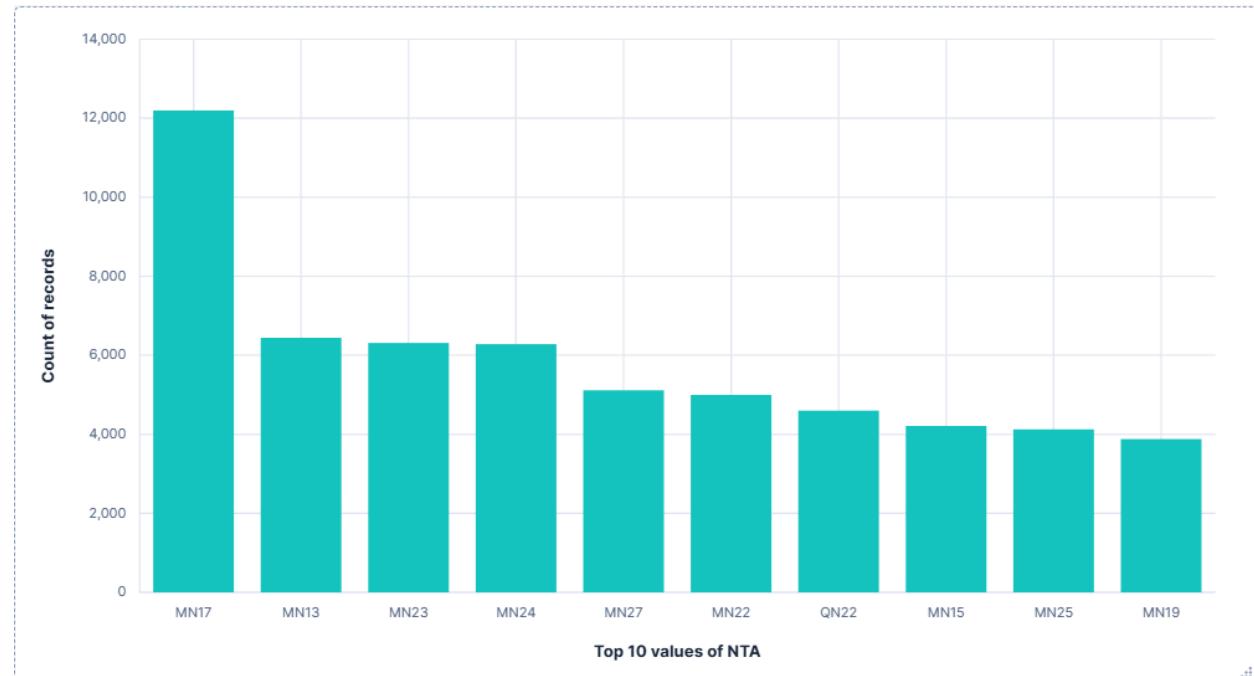
Cette requête permet à la fois de lister tous les quartiers de New York présents dans le dataset et d'identifier celui avec le plus de restaurants. NTA signifie Neighborhood Tabulation Area et sert à regrouper les restaurants par quartier géographique au sein des 5 boroughs de New York.

La première partie de la requête utilise une agrégation de type *cardinality* sur le champ NTA pour avoir le nombre total de quartiers distincts.



La deuxième partie regroupe les restaurants par quartier grâce à une agrégation *terms* sur le même champ, triée par nombre de documents décroissant.

Une sous-agrégation sur le champ *BORO* permet de savoir à quel arrondissement appartient chaque quartier (ce n'était pas demandé, je l'ai affiché sans aucune raison).



```

1  {
2    "took": 66,
3    "timed_out": false,
4    "_shards": {
5      "total": 1,
6      "successful": 1,
7      "skipped": 0,
8      "failed": 0
9    },
10   "hits": {
11     "total": {
12       "value": 10000,
13       "relation": "gte"
14     },
15     "max_score": null,
16     "hits": []
17   },
18   "aggregations": {
19     "unique_neighborhoods": {
20       "value": 193
21     },
22     "neighborhoods": {
23       "doc_count_error_upper_bound": 0,
24       "sum_other_doc_count": 0,
25       "buckets": [
26         {
27           "key": "MN17",
28           "doc_count": 12195,
29           "boro": {
30             "doc_count_error_upper_bound": 0,
31             "sum_other_doc_count": 0,
32             "buckets": [
33               {
34                 "key": "Manhattan",
35                 "doc_count": 12195
36               }
37             ]
38           },
39         },
40       {
41         "key": "MN13",
42         "doc_count": 6442,
43         "boro": {
44           "doc_count_error_upper_bound": 0,
45           "sum_other_doc_count": 0,
46           "buckets": [
47             {
48               "key": "Manhattan",
49               "doc_count": 6442
50             }
51           ]
52         },
53       {
54         "key": "MN23",
55         "doc_count": 6312,
56         "boro": {
57           "doc_count_error_upper_bound": 0,
58           "sum_other_doc_count": 0,
59           "buckets": [
60             {
61               "key": "Manhattan",
62               "doc_count": 6312
63             }
64           ]
65         },
66       {
67         "key": "MN24",
68         "doc_count": 6281,
69         "boro": {
70           "doc_count_error_upper_bound": 0,
71           "sum_other_doc_count": 0,
72           "buckets": [
73             {
74               "key": "Manhattan",
75               "doc_count": 6281
76             }
77           ]
78         },
79       }
80     ],
81   }
}

```

Le résultat montre que le dataset contient 193 quartiers distincts à New York ("value" : 193 dans l'agrégation **unique\_neighborhoods**). Ensuite, la partie **neighborhoods** affiche les quartiers triés par nombre de restaurants décroissant.

Le premier élément du tableau ("key" : "MN17") correspond donc au quartier ayant le plus de restaurants, avec un total de 12 195 établissements ("doc\_count"). La sous-agrégation **boro** indique que ce quartier appartient à Manhattan. Le second qui contient 6442 établissements est également situé à Manhattan et ainsi de suite.

Pour résumer, il y a 193 quartiers répertoriés dans la base de données, et celui codé MN17 (Manhattan) est celui qui regroupe le plus grand nombre de restaurants avec 12195 restaurants.

## Q3

```
GET ny_restaurants/_search
{
  "_source": ["VIOLATION CODE", "VIOLATION DESCRIPTION"],
  "query": {
    "term": {
      "VIOLATION CODE": "04N"
    }
  },
  "size": 1
}
```

On filtre ici les documents dont le champ *VIOLATION CODE* est égal à "04N" et renvoie la description associée.

Le paramètre `_source` limite les résultats aux champs à afficher, ici le code et sa description, et `size: 1` suffit puisqu'un seul exemple de ce code permet de connaître sa signification.

```
1  {
2    "took": 5,
3    "timed_out": false,
4    "_shards": {
5      "total": 1,
6      "successful": 1,
7      "skipped": 0,
8      "failed": 0
9    },
10   "hits": {
11     "total": {
12       "value": 10000,
13       "relation": "gte"
14     },
15     "max_score": 3.090052,
16     "hits": [
17       {
18         "_index": "ny_restaurants",
19         "_id": "j9q2L5oBqrQtmEC6nocT",
20         "_score": 3.090052,
21         "_source": {
22           "VIOLATION CODE": "04N",
23           "VIOLATION DESCRIPTION": "Filth flies or food/refuse/sewage associated
24             with (FRSA) flies or other nuisance pests in establishment's food and/
25             or non-food areas. FRSA flies include house flies, blow flies, bottle
26             flies, flesh flies, drain flies, Phorid flies and fruit flies."
27         }
28       }
29     ]
30   }
```

On a donc le code "04N" qui correspond à la mention "*Filth flies or food/refuse/sewage associated with (FRSA) flies or other nuisance pests...*", c'est-à-dire la présence de mouches ou d'autres nuisibles dans les zones alimentaires ou non alimentaires de l'établissement.

## 04

```
GET ny_restaurants/_search
{
  "_source": ["DBA", "BORO", "BUILDING", "STREET", "ZIPCODE", "NTA", "GRADE"],
  "query": {
    "term": { "GRADE": "A" }
  },
  "collapse": {
    "field": "CAMIS"
  },
  "sort": [
    { "NTA": { "order": "asc" } },
    { "CAMIS": { "order": "asc" } }
  ],
  "size": 10000,
  "track_total_hits": true
}
```

Le filtre `term` sur le champ GRADE sélectionne uniquement les établissements notés "A".

Le paramètre `_source` limite les champs renvoyés aux informations principales : le nom du restaurant (`DBA`), son adresse (`BUILDING`, `STREET`, `ZIPCODE`), le borough (`BORO`) et le quartier (`NTA`). L'option `collapse` sur le champ `CAMIS` évite les doublons en ne gardant qu'un seul document par restaurant. Les résultats sont triés par quartier (`NTA`) puis par identifiant (`CAMIS`), et `track_total_hits` permet d'obtenir le nombre total d'établissements trouvés.

Le résultat ci-dessous indique qu'il y a environ 75 988 restaurants notés "A".

À chaque fois, on affiche le nom du restaurant, son adresse complète et son quartier. Par exemple, on voit que "FASCATI'S PIZZERIA", situé sur Henry Street à Brooklyn (`NTA` : `BK09`), apparaît en premier car on a mis qu'on affiche dans l'ordre alphabétique de leur `NTA` et de leur `CAMIS`.

```

1   {
2     "took": 314,
3     "timed_out": false,
4     "_shards": {
5       "total": 1,
6       "successful": 1,
7       "skipped": 0,
8       "failed": 0
9     },
10    "hits": {
11      "total": {
12        "value": 75988,
13        "relation": "eq"
14      },
15      "max_score": null,
16      "hits": [
17        {
18          "_index": "ny_restaurants",
19          "_id": "CUG2L5oBIftoHvtj0ioc",
20          "_score": null,
21          "_source": {
22            "DBA": "FASCATI'S PIZZERIA",
23            "BUILDING": "80",
24            "BORO": "Brooklyn",
25            "ZIPCODE": "11201",
26            "STREET": "HENRY STREET",
27            "GRADE": "A",
28            "NTA": "BK09"
29          },
30          "fields": {
31            "CAMIS": [
32              40366652
33            ]
34          },
35          "sort": [
36            "BK09",
37            40366652
38          ],
39        },
40        {
41          "_index": "ny_restaurants",
42          "_id": "Atq2L5oBqrQtmEC6zePg",
43          "_score": null,
44          "_source": {
45            "DRA": "MONTERO RAR & GRTII"
46          }
47        }
48      ]
49    }
50  }
51

```

## 05

```

GET ny_restaurants/_search
{
  "size": 0,
  "aggs": {
    "cuisines": {
      "terms": {
        "field": "CUISINE DESCRIPTION",
        "size": 1,
        "order": { "unique_restaurants": "desc" }
      },
      "aggs": {
        "unique_restaurants": {
          "cardinality": { "field": "CAMIS" }
        }
      }
    }
  }
}

```

On effectue une agrégation sur le champ *CUISINE DESCRIPTION*, qui contient la catégorie culinaire de chaque restaurant (par exemple : *American*, *Chinese*, *Italian*, etc.). Pour éviter de compter plusieurs fois un même restaurant ayant plusieurs inspections, on utilise une

sous-agrégation *cardinality* sur le champ *CAMIS*, qui représente l'identifiant unique d'un établissement.

Le tri **order**: { "unique\_restaurants": "desc" } classe les types de cuisine selon le nombre de restaurants uniques, et **size**: 1 fait en sorte que seul le plus populaire soit renvoyé.

```

1  {
2    "took": 85,
3    "timed_out": false,
4    "_shards": {
5      "total": 1,
6      "successful": 1,
7      "skipped": 0,
8      "failed": 0
9    },
10   "hits": {
11     "total": {
12       "value": 10000,
13       "relation": "gte"
14     },
15     "max_score": null,
16     "hits": []
17   },
18   "aggregations": {
19     "cuisines": {
20       "doc_count_error_upper_bound": -1,
21       "sum_other_doc_count": 184606,
22       "buckets": [
23         {
24           "key": "American",
25           "doc_count": 36510,
26           "unique_restaurants": {
27             "value": 5045
28           }
29         }
30       ]
31     }
32   }
33 }
```

Le résultat montre que la cuisine américaine ("key" : "American") est la plus représentée, avec environ 5 045 restaurants distincts sur un total de plus de 36 000 inspections liées à cette catégorie.

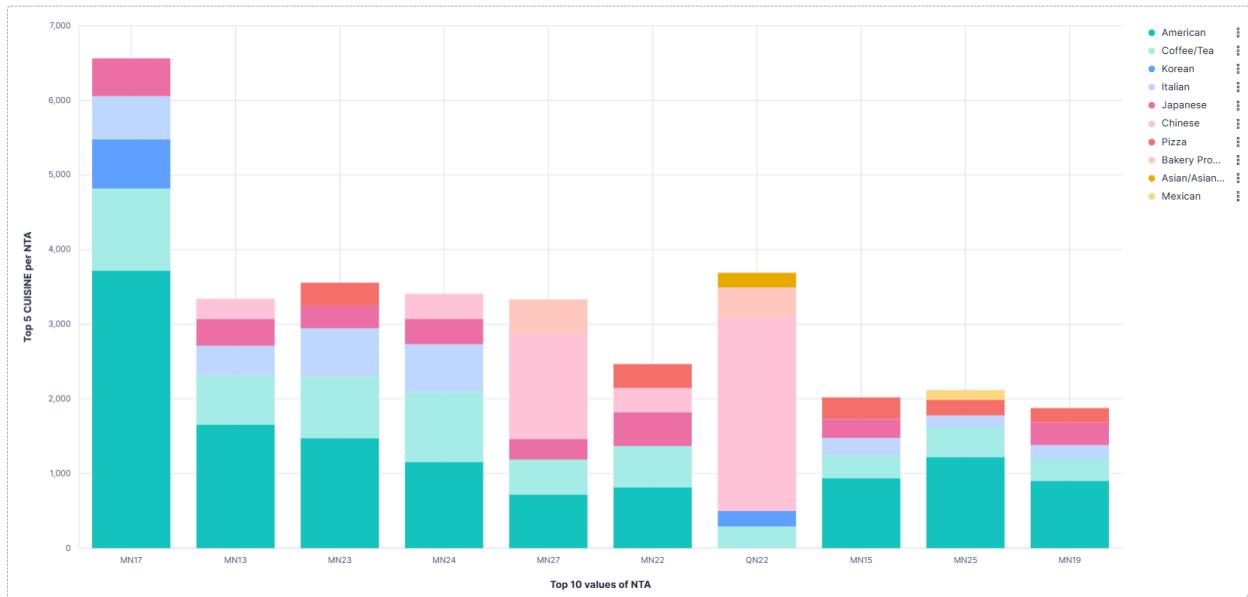
Pour répondre à la deuxième partie de la question ("et par quartier"), il suffirait d'ajouter une sous-agrégation *terms* sur le champ *NTA* pour compter les cuisines les plus populaires dans chaque quartier.

```
GET ny_restaurants/_search
{
  "size": 0,
  "aggs": {
    "by_nta": {
      "terms": {
        "field": "NTA",
        "size": 1000,
        "order": { "_key": "asc" }
      },
      "aggs": {
        "top_cuisine": {
          "terms": {
            "field": "CUISINE DESCRIPTION",
            "size": 1,
            "order": { "unique_restaurants": "desc" }
          },
          "aggs": {
            "unique_restaurants": {
              "cardinality": { "field": "CAMIS" }
            }
          }
        }
      }
    }
  }
}
```

Ici on regroupe d'abord les données par quartier (*NTA*), puis par type de cuisine (*CUISINE DESCRIPTION*).

Le résultat montre qu'en général la cuisine américaine est la plus présente dans plusieurs quartiers. Par exemple, dans le quartier BK09 à Brooklyn, elle apparaît comme la plus populaire avec 28 restaurants distincts avec la cuisine *American*.

Ci-dessous, on affiche les 5 cuisines les plus populaires dans 10 quartiers différents (*NTA*).



```
GET ny_restaurants/_search
{
  "size": 0,
  "aggs": {
    "last_inspection": {
      "max": {
        "field": "INSPECTION DATE",
        "format": "yyyy-MM-dd"
      }
    }
  }
}
```

Cette requête cherche la date la plus récente d'inspection en calculant le maximum sur le champ *INSPECTION DATE*.

On ne renvoie pas de documents, seulement l'agrégation `last_inspection`.

Le paramètre "`format`": "yyyy-MM-dd" force un affichage clair de la date, pour ne pas confondre DD-MM-YYYY et MM-DD-YYYY.

Dans le résultat ci-dessous, la valeur lisible est

`aggregations.last_inspection.value_as_string = "2024-04-02"` (2 avril 2024) :  
c'est donc la dernière date d'inspection du dataset.

```
1  {
2    "took": 0,
3    "timed_out": false,
4    "_shards": {
5      "total": 1,
6      "successful": 1,
7      "skipped": 0,
8      "failed": 0
9    },
10   "hits": {
11     "total": {
12       "value": 10000,
13       "relation": "gte"
14     },
15     "max_score": null,
16     "hits": []
17   },
18   "aggregations": {
19     "last_inspection": {
20       "value": 1712016000000,
21       "value_as_string": "2024-04-02"
22     }
23   }
24 }
```

## 07

```
GET ny_restaurants/_search
{
  "_source": ["DBA", "BUILDING", "STREET", "BORO", "ZIPCODE", "NTA", "GRADE", "CUISINE DESCRIPTION"],
  "track_total_hits": true,
  "query": {
    "bool": {
      "must": [
        { "term": { "BORO": "Brooklyn" } },
        { "term": { "GRADE": "A" } },
        { "term": { "CUISINE DESCRIPTION": "Chinese" } }
      ]
    }
  },
  "collapse": { "field": "CAMIS" },
  "aggs": {
    "distinct_restaurants": {
      "cardinality": { "field": "CAMIS" }
    }
  },
  "sort": [
    { "NTA": { "order": "asc" } },
    { "CAMIS": { "order": "asc" } }
  ],
  "size": 10000
}
```

Cette requête extrait la liste des restaurants chinois notés A à Brooklyn.

- Le filtre `bool.must` restreint aux documents où *BORO* = "Brooklyn", *GRADE* = "A" et *CUISINE DESCRIPTION* = "Chinese".
- `collapse` sur *CAMIS* évite les doublons (un seul hit par restaurant).
- `_source` ne renvoie que les champs utiles (nom, adresse, quartier, grade, type de cuisine).
- Le tri se fait par quartier (*NTA*) puis par identifiant (*CAMIS*) pour un ordre stable.
- L'agg `distinct_restaurants` (cardinality sur *CAMIS*) donne le nombre de restaurants uniques correspondant.
- `track_total_hits: true` fournit le total de documents qui matchent (avant déduplication).

```

1  {
2    "took": 17,
3    "timed_out": false,
4    "_shards": {
5      "total": 1,
6      "successful": 1,
7      "skipped": 0,
8      "failed": 0
9    },
10   "hits": {
11     "total": {
12       "value": 1883,
13       "relation": "eq"
14     },
15     "max_score": null,
16     "hits": [
17       {
18         "_index": "ny_restaurants",
19         "_id": "UkC2L5oBIfptoHvtjpcv2",
20         "_score": null,
21         "_source": {
22           "DBA": "LICHEE NUT",
23           "BUILDING": "162",
24           "BORO": "Brooklyn",
25           "CUISINE DESCRIPTION": "Chinese",
26           "ZIPCODE": "11201",
27           "STREET": "MONTAGUE STREET",
28           "GRADE": "A",
29           "NTA": "BK09"
30         },
31       ],
32       "fields": {
33         "CAMIS": [
34           40605862
35         ],
36       },
37       "sort": [
38         "BK09",
39         40605862
40       ],
41     },
42     "fields": {
43       "CAMIS": [
44         40605862
45       ],
46       "sort": [
47         "BK09",
48         40605862
49       ],
50     }
51   }
52 }
```

Dans le résultat montré, `hits.total.value = 1883` indique 1883 documents correspondant au filtre, et la liste affiche des établissements comme "LICHEE NUT" (BK09, Brooklyn, A) avec leur adresse complète. L'agrégation `distinct_restaurants.value` est la valeur à reporter si on veut le compte de restos uniques.

## Q8

```
GET ny_restaurants/_search
{
  "_source": [ "DBA", "BUILDING", "STREET", "BORO", "ZIPCODE", "NTA", "CAMIS" ],
  "query": {
    "match": {
      "DBA": {
        "query": "LADUREE",
        "operator": "and"
      }
    }
  },
  "aggs": {
    "distinct_restaurants": {
      "cardinality": { "field": "CAMIS" }
    }
  },
  "collapse": { "field": "CAMIS" },
  "size": 100
}
```

Une requête de type **match** a été utilisée afin de retrouver tous les documents correspondant au nom *LADUREE*.

L'opérateur "**and**" a été ajouté pour rendre la recherche plus stricte : il garantit que tous les mots saisis doivent être présents dans le nom du restaurant, évitant ainsi les correspondances partielles.

Les résultats ont été limités aux champs liés à l'adresse (*BUILDING*, *STREET*, *ZIPCODE*, *BORO*, *NTA*) et dédupliqués grâce au **collapse** sur *CAMIS*, afin de ne conserver qu'un enregistrement par établissement.

Le résultat ci-dessous montre 35 documents (plusieurs inspections) mais 2 restaurants distincts :

- LADUREE — 864 MADISON AVENUE, Manhattan 10021 (NTA : MN40)
- LADUREE SOHO — 398 WEST BROADWAY, Manhattan 10012 (NTA : MN24)

```

1   {
2     "took": 4,
3     "timed_out": false,
4     "_shards": {
5       "total": 1,
6       "successful": 1,
7       "skipped": 0,
8       "failed": 0
9     },
10    "hits": {
11      "total": { 36
12        "value": 35, 37
13        "relation": "eq" 38
14      }, 39
15      "max_score": 11.699377, 40
16      "hits": [ 41
17        {
18          "_index": "ny_restaurants", 43
19          "_id": "9Nq2L5oBqrQtmEC6rZHp", 44
20          "_score": 11.699377, 45
21          "_source": { 46
22            "DBA": "LADUREE", 47
23            "BUILDING": "864", 48
24            "BORO": "Manhattan", 49
25            "CAMIS": 50054046, 50
26            "ZIPCODE": "10021", 51
27            "STREET": "MADISON AVENUE", 52
28            "NTA": "MN40" 53
29          }, 54
30          "fields": { 55
31            "CAMIS": [ 56
32              50054046 57
33            ] 58
34          } 59
35        }, 60
36        {
37          "_index": "ny_restaurants", 61
38          "_id": "o9q2L5oBqrQtmEC6rZHo", 62
39          "_score": 9.67333,
40          "_source": {
41            "DBA": "LADUREE SOHO",
42            "BUILDING": "398",
43            "BORO": "Manhattan",
44            "CAMIS": 50006574,
45            "ZIPCODE": "10012",
46            "STREET": "WEST BROADWAY",
47            "NTA": "MN24"
48          },
49          "fields": {
50            "CAMIS": [
51              50006574
52            ]
53          }
54        }
55      ],
56      "aggregations": {
57        "distinct_restaurants": {
58          "value": 2
59        }
60      }
61    }
62  }

```

## 09

```
GET ny_restaurants/_search
{
  "size": 0,
  "query": {
    "match_phrase": {
      "VIOLATION DESCRIPTION": "Hot TCS food item not held at or above 140 °F."
    }
  },
  "aggs": {
    "by_cuisine": {
      "terms": {
        "field": "CUISINE DESCRIPTION",
        "size": 1,
        "order": { "affected_restaurants": "desc" }
      },
      "aggs": {
        "affected_restaurants": {
          "cardinality": { "field": "CAMIS" }
        }
      }
    }
  }
}
```

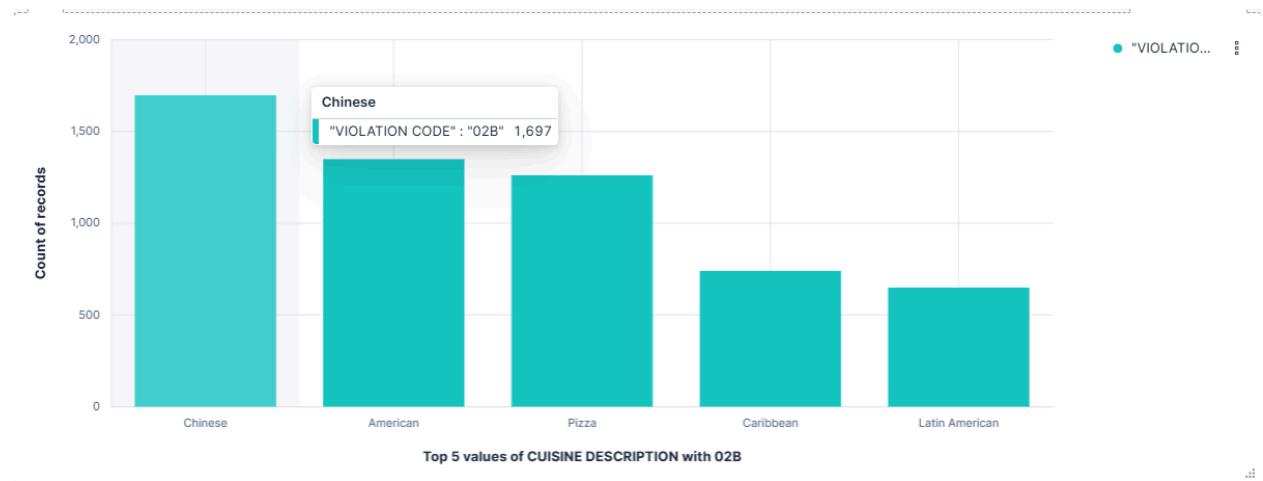
Il faut d'abord commencer par repérer la phrase exacte du problème dans les données de *VIOLATION DESCRIPTION* : "Hot TCS food item not held at or above 140°F."

Le champ contenant une phrase complète, la solution la plus précise a été d'utiliser **match\_phrase** plutôt qu'un simple **term**, afin de cibler uniquement les enregistrements contenant cette description exacte. Ensuite, une agrégation sur *CUISINE DESCRIPTION* a permis de compter le nombre de restaurants distincts (*CAMIS*) concernés par cette violation, et d'en déduire le type de cuisine le plus touché.

Le résultat ci-dessous montre que la cuisine chinoise est celle la plus fréquemment associée à cette violation.

```
1  {
2      "took": 32,
3      "timed_out": false,
4      "_shards": {
5          "total": 1,
6          "successful": 1,
7          "skipped": 0,
8          "failed": 0
9      },
10     "hits": {
11         "total": {
12             "value": 7877,
13             "relation": "eq"
14         },
15         "max_score": null,
16         "hits": []
17     },
18     "aggregations": {
19         "by_cuisine": {
20             "doc_count_error_upper_bound": -1,
21             "sum_other_doc_count": 6721,
22             "buckets": [
23                 {
24                     "key": "Chinese",
25                     "doc_count": 1156,
26                     "affected_restaurants": {
27                         "value": 903
28                     }
29                 }
30             ]
31         }
32     }
33 }
```

On a remarqué que ce *CODE VIOLATION*, correspond à 02B et grâce à ceci on affiche ci-dessous le graphique correspondant.



## Q10

```
GET ny_restaurants/_search
{
  "size": 0,
  "aggs": {
    "top_violations": {
      "terms": {
        "field": "VIOLATION_CODE",
        "size": 5,
        "order": { "_count": "desc" }
      },
      "aggs": {
        "example_description": {
          "top_hits": {
            "_source": ["VIOLATION_CODE", "VIOLATION_DESCRIPTION"],
            "size": 1
          }
        },
        "affected_restaurants": {
          "cardinality": { "field": "CAMIS" }
        }
      }
    }
  }
}
```

Pour trouver le Top 5 des violations, l'idée a été de regrouper par identifiant de violation plutôt que par libellé.

Le champ *VIOLATION DESCRIPTION* est textuel et peut varier (phrases longues, ponctuation), donc pas fiable pour un classement. Le champ *VIOLATION CODE* est, lui, normalisé (*keyword*) et identifie chaque type de violation de façon stable.

La requête fait donc un classement par fréquence des codes (les 5 plus fréquents). Pour rendre le résultat lisible, une sous-requête `top_hits` récupère une description d'exemple pour chaque code. Et pour mesurer l'impact, une cardinalité sur *CAMIS* donne le nombre de restaurants distincts touchés par chaque code.

Interprétation rapide des résultats fournis ci-dessous :

- 10F — *Non-food contact surfaces...* → 30 893 occurrences, 19 311 restos distincts
- 08A — *Not free of conditions conducive to pests* → 23 539, 14 001
- 06D — *Food contact surface not properly washed/rinsed/sanitized* → 14 849, 11 021
- 04L — *Evidence of mice...* → 14 465, 9 190
- 02G — *Cold TCS food above required temps...* → 13 170, 9 945

Ce choix (agrégé par code) garantit un top véritablement comparable, puis on ajoute la description pour l'explication et le nombre de *CAMIS* uniques pour l'ampleur réelle.

```

1  {
2    "took": 125,
3    "timed_out": false,
4    "_shards": {
5      "total": 1,
6      "successful": 1,
7      "skipped": 0,
8      "failed": 0
9    },
10   "hits": {
11     "total": {
12       "value": 10000,
13       "relation": "gte"
14     },
15     "max_score": null,
16     "hits": []
17   },
18   "aggregations": {
19     "top_violations": {
20       "doc_count_error_upper_bound": 0,
21       "sum_other_doc_count": 123052,
22       "buckets": [
23         {
24           "key": "10F",
25           "doc_count": 30893,
26           "example_description": {
27             "hits": {
28               "total": {
29                 "value": 30893,
30                 "relation": "eq"
31               },
32               "max_score": 1,
33               "hits": [
34                 {
35                   "_index": "ny_restaurants",
36                   "_id": "htq2l5oBqrQtmEC6nqcT",
37                   "_score": 1,
38                   "_source": {
39                     "VIOLATION CODE": "10F",
40                     "VIOLATION DESCRIPTION": "Non-food contact surface improperly constructed. Unacceptable material used. Non-food contact surface or equipment improperly maintained and/or not properly sealed, raised, spaced or movable to allow accessibility for cleaning on all sides, above and underneath the unit."
41                   }
42                 }
43               }
44             }
45           }
46         }
47       }
48     }
49   }
50 }
```

```

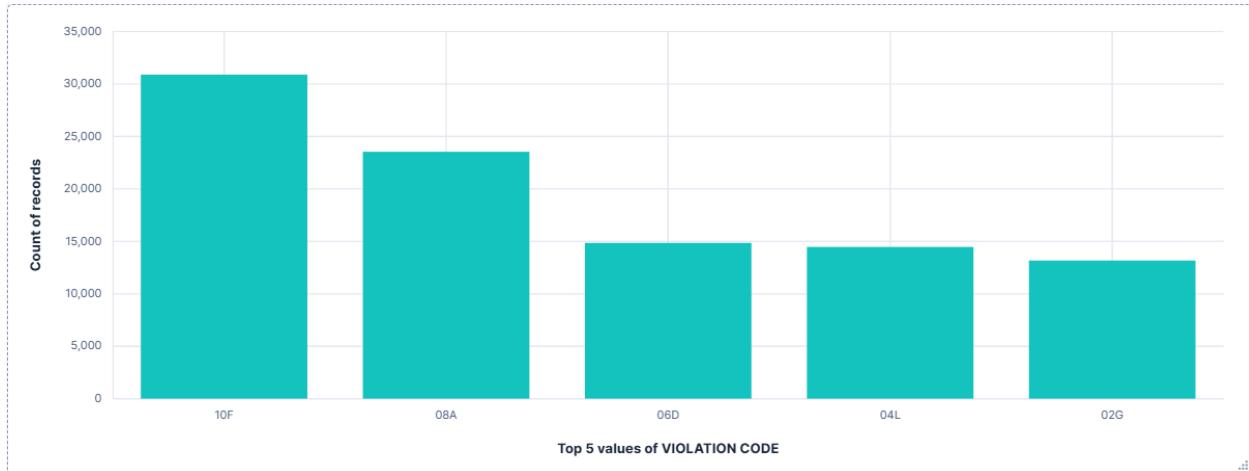
43   |   ],
44   | }
45   },
46   "affected_restaurants": {
47     "value": 19311
48   }
49 },
50 {
51   "key": "08A",
52   "doc_count": 23539,
53   "example_description": {
54     "hits": {
55       "total": {
56         "value": 23539,
57         "relation": "eq"
58       },
59       "max_score": 1,
60       "hits": [
61         {
62           "_index": "ny_restaurants",
63           "_id": "hdq2L5oBqrQtmEC6nocT",
64           "_score": 1,
65           "_source": {
66             "VIOLATION CODE": "08A",
67             "VIOLATION DESCRIPTION": "Establishment is not free of harborage or conditions conducive to rodents, insects or other pests."
68           }
69         }
70       ]
71     }
72   },
73   "affected_restaurants": {
74     "value": 14001
75   }
76 },
77 {
78   "key": "06D",
79   "doc_count": 14849,
80   "example_description": {
81     "hits": {
82       "total": {
83         "value": 14849,
84         "relation": "eq"
85       },
86       "max_score": 1,
87       "hits": [
88         {
89           "_index": "ny_restaurants",
90           "_id": "19q2L5oBqrQtmEC6nocT",
91           "_score": 1,
92           "_source": {
93             "VIOLATION CODE": "06D",
94             "VIOLATION DESCRIPTION": "Food contact surface not properly washed, rinsed and sanitized after each use and following any activity when contamination may have occurred."
95           }
96         }
97       ]
98     }
99   },
100  "affected_restaurants": {
101    "value": 11021
102  }
103 },
104 {
105   "key": "04L",
106   "doc_count": 14465,
107   "example_description": {
108     "hits": {
109       "total": {
110         "value": 14465,
111         "relation": "eq"
112       },
113       "max_score": 1,
114       "hits": [
115         {
116           "_index": "ny_restaurants",
117           "_id": "g9q2L5oBqrQtmEC6nocT",
118           "_score": 1,
119           "_source": {
120             "VIOLATION CODE": "04L",
121             "VIOLATION DESCRIPTION": "Evidence of mice or live mice in establishment's food or non-food areas."
122           }
123         }
124       ]
125     }
126   },
127   "affected_restaurants": {
128     "value": 9198
129   }

```



```

130 },
131 {
132   "key": "02G",
133   "doc_count": 13170,
134   "example_description": {
135     "hits": {
136       "total": {
137         "value": 13170,
138         "relation": "eq"
139       }
140       "max_score": 1,
141       "hits": [
142         {
143           "_index": "ny_restaurants",
144           "_id": "mNg2l5oBqrQtmEC6nocT",
145           "_score": 1,
146           "_source": {
147             "VIOLATION_CODE": "02G",
148             "VIOLATION_DESCRIPTION": "Cold TCS food item held above 41 °F; smoked or processed fish held above 38 °F; intact raw eggs held above 45 °F; or reduced oxygen packaged (ROP) TCS foods held above required temperatures except during active necessary preparation."
149           }
150         }
151       ]
152     }
153   },
154   "affected_restaurants": {
155     "value": 9945
156   }
157 }
158 ]
159 }
160 }
161 }
```



## II. Dashboard et MAP

Pour pouvoir créer un *Dahsboard*, on a dû ajouter la latitude et la longitude en créant un champ *location* pour que la *MAP* puisse lire les coordonnées car on avait seulement Latitude et Longitude en **double**, donc Kibana ne proposait aucun “geo field” et affichait l’erreur “Data view does not contain any geospatial fields”.

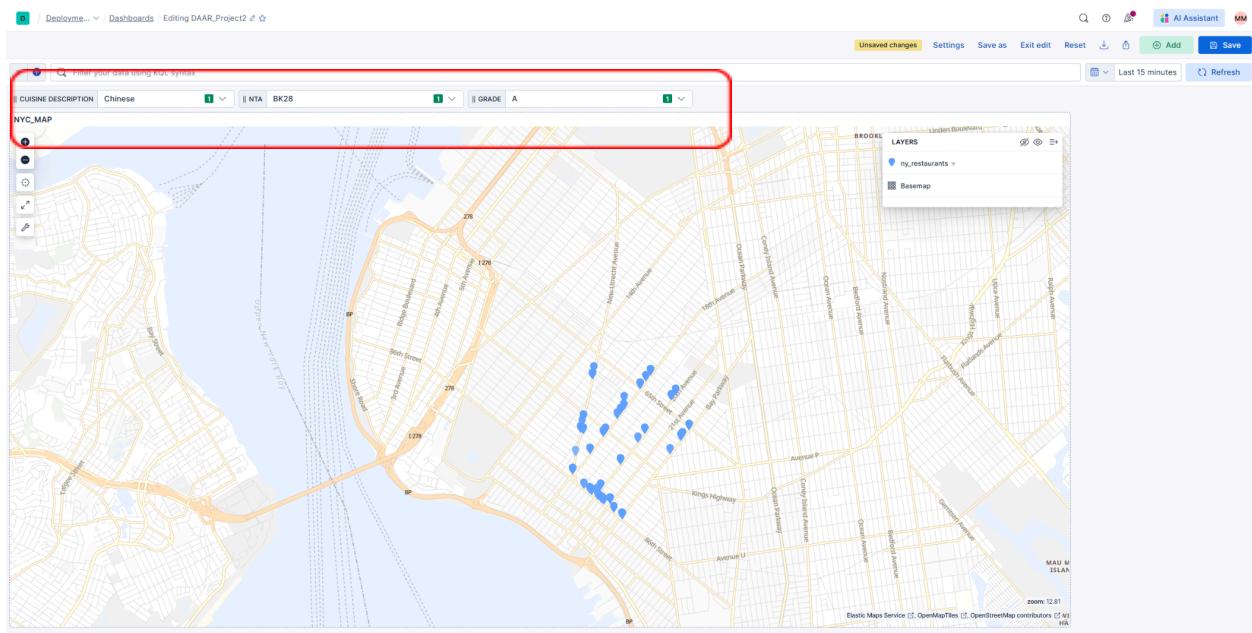
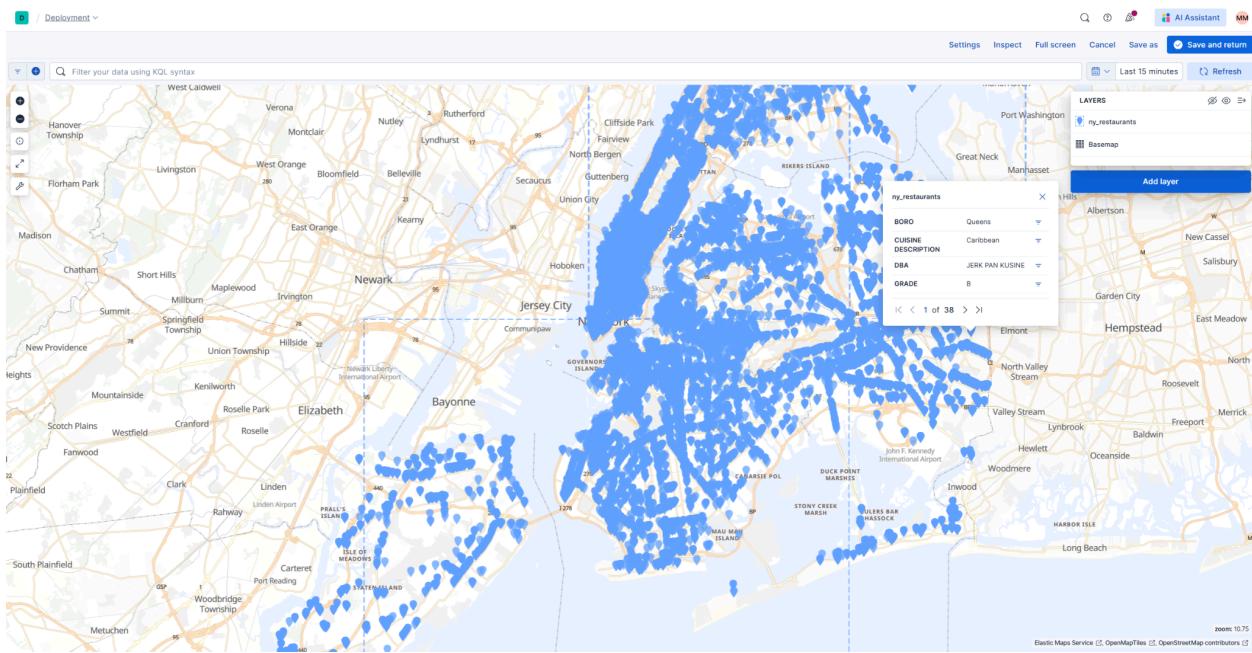
La démarche a été la suivante :

- Partir des champs existants **Latitude / Longitude** et créer un champ géo dédié : ajouter **location** au mapping en **geo\_point**.
- Renseigner ce nouveau champ pour tous les documents en le construisant à partir des valeurs existantes, au format attendu [lon, lat]. Pour éviter de réindexer le jeu de données, utiliser un **\_update\_by\_query** avec un script painless qui copie **Longitude** et **Latitude** vers **location**.
- Rafraîchir la data view dans Kibana, puis, dans Maps, choisir **location** comme Geospatial field. La couche “Documents” peut alors s’afficher en points sur la carte.

C'est pour cette raison qu'on a exécuté les requêtes suivantes :

```
PUT ny_restaurants/_mapping
{
  "properties": {
    "location": { "type": "geo_point" }
  }
}

POST ny_restaurants/_update_by_query
{
  "script": {
    "source": """
      if (ctx._source.containsKey('Latitude') && ctx.
        _source.containsKey('Longitude')) {
        double lat = ctx._source.Latitude;
        double lon = ctx._source.Longitude;
        ctx._source.location = [lon, lat];
      }
    """,
    "lang": "painless"
  }
}
```



On peut voir dans la capture d'écran ci-dessus, qu'on affiche les restaurants chinois avec une note "A" dans le quartier BK28 grâce aux filtres qu'on a ajoutés.